

Relevantes in Kurzform

Worum geht es hier? Prinzip verstehen, von 'Machine Learning' (ML) in angewandter Forschung zu öffentlicher psychischer Gesundheit.

Primäres Forschungsziel? Unterstützung für Kliniker/in, um durchschnittlichen Entscheidungserfolg zu verbessern, ob Individuum x den fraglichen Outcome hat (Diagnostik) oder entwickeln wird (Prognostik).

Forschungsstand klinischer Vorhersagemodelle Psychologie (anno 2025):

'[...] efforts have been inhibited by a preponderance of bias and overfitting, **while the generalizability and clinical utility** of many published models **has yet to be formally established**. [...] future research has the potential to generate risk prediction tools capable of **enhancing clinical decision-making in psychiatric care**.' (Siehe Abstract, in: Meehan et al., [2022](#)).

Weitere Beispielarbeiten zum aktuellen Forschungsstand:

In syst. Review (Salazar de Pablo et al., [2024](#)) zu 'Individualized prediction models in ADHD' (Eingeschlossen wurden 100 Modelle, entspricht in diesem Fall 100 Publikationen) steht: Future studies should consider net benefit approaches for the evaluation of prediction models for ADHD, which were not used in any of the studies in this review. Richter et al. ([2025](#)) versuchten Schweregrad depressiver Symptomatik vorherzusagen, mit Fokus auf klinischer Nützlichkeit. Weil sie den Symptomschweregrad auf eine kontinuierliche Skala gesetzt haben, haben sie Pearson Korrelation als Performanzmass verwendet (net benefit geht nur, wenn der Outcome dichotom ist).

Büscher et al. ([2024](#)) haben in ihr syst. Review zu 'passive sensing for the prediction of suicidal thoughts and behaviors' 11 Vorhersagestudien, 10 Machbarkeitsstudien und 7 Studienprotokolle eingeschlossen. Es scheinen nur sehr begrenzte 'Erfolge' vorzuliegen

(3 out of 4 studies find no incremental value).

Newby et al. (2024) ist ein expert review, das der Frage nachgeht, mit welchem 'Erfolg' sog. real world data aus elektronischen Krankenakten verwendet werden könnten, zur Vorhersage klinisch psychologischer Outcomes. Grösste Herausforderung (siehe Abstract): clinically important 'signal' is often contained in both structured and unstructured (narrative or "free-text") data; wie funktioniert hier 'die Guten ins Töpfchen, ...'?

Primäres Forschungsziel wie erreichen? Vorhersagemodelle primär in bestmöglicher Übereinstimmung mit dem primären Forschungsziel bewerten, also: Klinischer Entscheidungsnutzen (= wofür das Model in der realen Welt eingesetzt werden soll).

Bewertung des klinischen Entscheidungsnutzens eines Vorhersagemodels: In der jetzigen Forschungsphase können Vorhersagemodelle nur auf eine Weise sinnvoll bewertet werden. Man nimmt einen existierenden Datensatz, bei dem der Outcome bereits für alle Personen vorliegt. Man fragt sich, welchen Entscheidungsnutzen das Vorhersagemodel gehabt hätte, wenn man es in der Vergangenheit für die Personen aus der Stichprobe genutzt hätte. Wie viele der Personen, die den Outcome entwickelt hatten, wären richtig vorhergesagt worden (true positives)? Wie viele false positives hätte es gegeben, wenn man sich auf die Modelvorhersage verlassen hätte? Usw.

Wahl des besten Models, falls ein Einsatz in der realen Welt angestrebt wird: Hier gäbe es kein besseres Kriterium als das, das auch angewandt wird, wenn man z.B. eine/n Musiker/in für einen Auftritt buchen würde. Es wird der/die Musiker/in gebucht, die (in der Vergangenheit) durchschnittlich besser 'performt' hat als alle vergleichbaren Musiker/innen. Man erhofft sich eine sehr gute Vorstellung, will aber gleichzeitig sicher gehen, dass die Vorstellung selbst dann erfolgreich genug ist, wenn sie schlecht sein sollte. Dieser Gedanke liegt allen Methoden der Kreuzvalidierung (resampling, boot-

strapping, usw.) zugrunde.

Bedeutsames Problem (siehe rote Schrift auf Seite 1): Die publizierten Resultate zu klinischen Vorhersagemodellen im Bereich öffentlicher psychischer Gesundheit sind invers(!) zum primären Forschungsziel. Clinical utility wird (fast gar) nicht berichtet. Diskriminanz (meist area under the receiver operating characteristic curve; AUC) wird am häufigsten berichtet (> 90% aller Publikationen), obwohl es am wenigsten dem primären Forschungszweck entspricht. Kalibrierung steht der klinischen Nützlichkeit wesentlich näher als Diskriminanz, wird jedoch selten berichtet (ca. 5-10% aller Publikationen).

Meiner Meinung nach derzeit grösstes Problem: Die zwei 'häufigst' genannten Ergebnisse von Vorhersagemodellen (Diskriminanz und Kalibrierung) können sich leicht widersprechen und tun dies entsprechend (relativ) häufig (Assel et al., 2017; Holmberg et al., 2013; Shah et al., 2022). Es wird also nicht nur das primär am besten geeignete Performanzmass (fast komplett) beseite gelassen, sondern es wird vorhersehbar Verwirrung geschaffen, weil laut Diskriminanz Model A 'besser' ist als Model B, laut Kalibrierung jedoch B 'besser' ist als A. Das Merkwürdigste an dieser Sache ist einerseits, dass sich scheinbar niemand für dieses 'Detail' zu interessieren scheint, und andererseits, dass das eigentlich primäre Performanzmass net benefit diesen potentiellen Widerspruch (zwischen Diskriminanz und Kalibrierung) auflöst, weil es beide in sich vereinigt, **und dazu(!)** das relevanteste Ergebnis liefert, aus Sicht des primären Forschungsziels klinischer Vorhersagemodelle.

Fazit: Wo auch immer ein Vorhersagemodel für die klinische Praxis präsentiert wird, sollte kein Entscheidungsergebnis, z.B. net benefit, präsentiert werden, sollte zumindest kritisch nachgefragt werden, aus welchem Grund kein solches Mass präsentiert wurde.